Activity - Estimating Lifetime

- Use Telco Churn dataset and build a Kaplan Meier survival analysis.
- Compare lifetime between different payment methods.

0. Setup

In [62]:
```
# Colab ไม่มี lifelines ติดมาให้ / เครื่องตัวเองก็รันครั้งเดียวพอ
!pip install -q lifelines
```

```
[notice] A new release of pip available: 22.3 -> 26.2.1
[notice] To update, run: python.exe -m pip install --upgrade pip
```

In [63]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import lifelines

print("lifelines :", lifelines.__version__)
```

```
lifelines : 0.30.3
```

1. Load dataset

In [64]:
```
df = pd.read_csv('Telco+Churn.csv')

print("shape :", df.shape)
print("cols  :", list(df.columns))
df.head()
```

```
shape : (7043, 21)
cols  : ['customerID', 'gender', 'SeniorCitizen', 'Partner', 'Dependents', 'tenure', 'PhoneService', 'MultipleLines',
'InternetService', 'OnlineSecurity', 'OnlineBackup', 'DeviceProtection', 'TechSupport', 'StreamingTV', 'StreamingMovies',
'Contract', 'PaperlessBilling', 'PaymentMethod', 'MonthlyCharges', 'TotalCharges', 'Churn']
```

Out[64]:

	customerID	gender	SeniorCitizen	Partner	Dependents	tenure	PhoneService	MultipleLines	InternetService	OnlineSec
0	7590-VHVEG	Female	0	Yes	No	1	No	No phone service	DSL	
1	5575-GNVDE	Male	0	No	No	34	Yes	No	DSL	
2	3668-QPYBK	Male	0	No	No	2	Yes	No	DSL	
3	7795-CFOCW	Male	0	No	No	45	No	No phone service	DSL	
4	9237-HQITU	Female	0	No	No	2	Yes	No	Fiber optic	

5 rows × 21 columns

In [65]:
```
# survival analysis ใช้แค่ 3 คอลัมน์นี้
#   tenure       -> T  duration   อยู่กับเรามากี่เดือน
```

```
#   Churn         -> E  event      ยกเลิกจริงไหม
#   PaymentMethod -> group         ตัวที่โจทย์สั่งให้เทียบ
print(df[['tenure', 'Churn', 'PaymentMethod']].head(10))
print()
print("missing:")
print(df[['tenure', 'Churn', 'PaymentMethod']].isna().sum())
```

```
   tenure Churn              PaymentMethod
0       1    No           Electronic check
1      34    No               Mailed check
2       2   Yes               Mailed check
3      45    No  Bank transfer (automatic)
4       2   Yes           Electronic check
5       8   Yes           Electronic check
6      22    No    Credit card (automatic)
7      10    No               Mailed check
8      28   Yes           Electronic check
9      62    No  Bank transfer (automatic)

missing:
tenure           0
Churn            0
PaymentMethod    0
dtype: int64
```

2. mapping Churn into event 1/0

Churn = Yes -> 1 เห็นเหตุการณ์จริง (ตาย)

Churn = No -> 0 censored ยังอยู่ ณ วันเก็บข้อมูล ไม่ได้แปลว่าจะอยู่ตลอดไป

In [66]:

```
print(df['Churn'].value_counts(), "\n")

df['event'] = (df['Churn'] == 'Yes').astype(int)

# เช็คว่าแมพถูก ตัวเลขต้องตรงกับข้างบน แล้วต้องไม่มีช่องหลุดมุม
print(pd.crosstab(df['Churn'], df['event']))
print("\ncensored rate = %.3f" % (1 - df['event'].mean()))
```

```
Churn
No     5174
Yes    1869
Name: count, dtype: int64

event     0     1
Churn
No     5174     0
Yes       0  1869

censored rate = 0.735
```

3. checking tenure feature

In [67]:

```
print(df['tenure'].describe(), "\n")
print("tenure == 0 :", (df['tenure'] == 0).sum(), "rows")
print(df.loc[df['tenure'] == 0, ['tenure', 'Churn', 'TotalCharges', 'PaymentMethod']].head())
```

```
count    7043.000000
mean       32.371149
std        24.559481
min         0.000000
25%         9.000000
50%        29.000000
75%        55.000000
max        72.000000
Name: tenure, dtype: float64

tenure == 0 : 11 rows
      tenure Churn TotalCharges              PaymentMethod
488        0    No               Bank transfer (automatic)
753        0    No                         Mailed check
936        0    No                         Mailed check
1082       0    No                         Mailed check
1340       0    No                 Credit card (automatic)
```

In [68]:

```
# Dorp tenure == 0 (อยู่กับเรามา 0 เดือน -> ลูกค้าใหม่)

before = len(df)
df = df[df['tenure'] > 0].copy()

print("dropped :", before - len(df))
print("shape   :", df.shape)
```

```
dropped : 11
shape   : (7032, 22)
```

4. ประกอบ T กับ E

In [69]:

```
T = df['tenure']       # duration
E = df['event']        # event observed

print("T : n=%d  range %d - %d เดือน" % (len(T), T.min(), T.max()))
print("E : events=%d  censored=%d" % (E.sum(), (E == 0).sum()))
```

```
T : n=7032  range 1 - 72 เดือน
E : events=1869  censored=5163
```

5. Kaplan-Meier for all dataset (baseline)

ยังไม่แยกกลุ่ม เอาไว้เป็นเส้นอ้างอิงว่าภาพรวมหน้าตายังไง

In [70]:

```
from lifelines import KaplanMeierFitter

kmf = KaplanMeierFitter()
kmf.fit(T, event_observed=E, label='All customers')

# ตาราง S(t) ทีละ step เริ่มที่ 1.0 แล้วลดลงทุกครั้งที่มีคน churn
print(kmf.survival_function_.head(10))
```

```
          All customers
timeline
0.0            1.000000
1.0            0.945961
2.0            0.927835
3.0            0.913725
4.0            0.901045
5.0            0.891111
6.0            0.884826
7.0            0.876713
8.0            0.869933
9.0            0.862394
```

In [71]:

```
print("median survival time :", kmf.median_survival_time_)

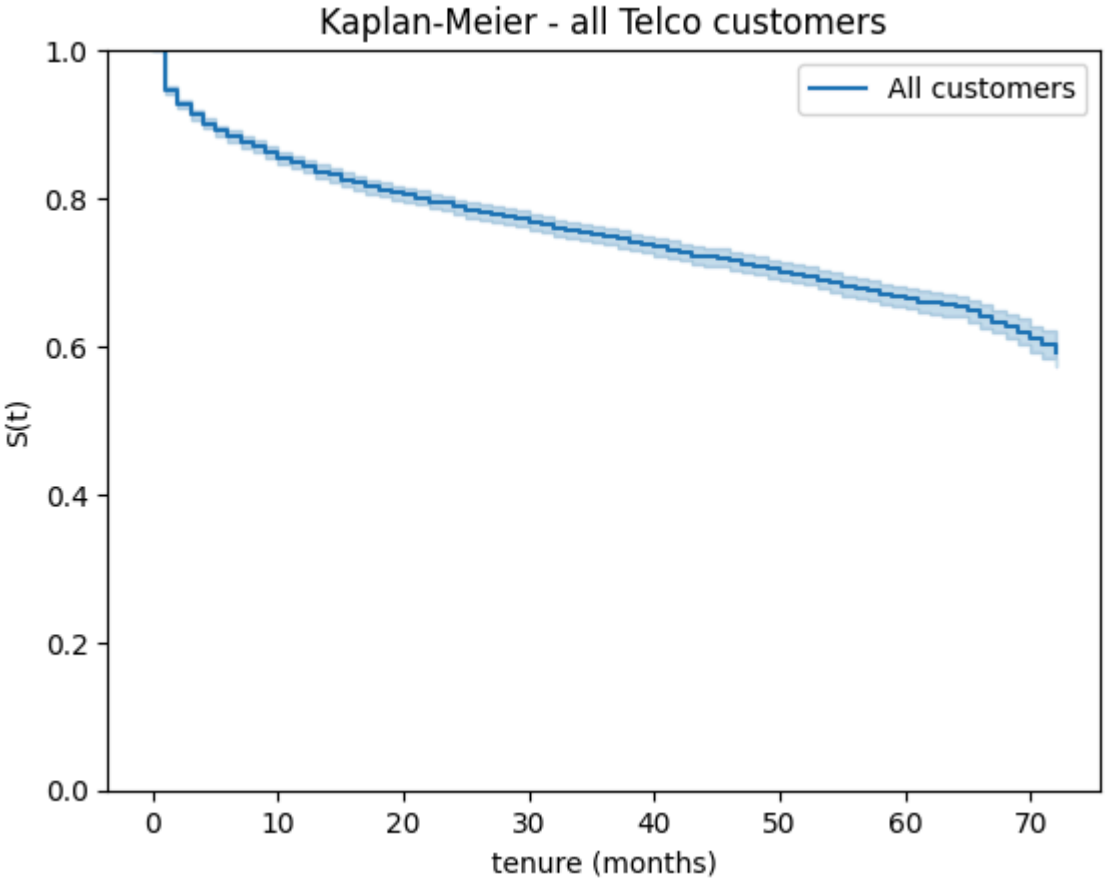
for t in [6, 12, 24, 48, 72]:
    print("S(%2d) = %.3f" % (t, kmf.survival_function_at_times(t).iloc[0]))
```

```
median survival time : inf
S( 6) = 0.885
S(12) = 0.843
S(24) = 0.789
S(48) = 0.709
S(72) = 0.593
```

> median go to `inf` becauase S(t) never reach 0.5

In [72]:

```
kmf.plot_survival_function()
plt.title('Kaplan-Meier - all Telco customers')
plt.xlabel('tenure (months)')
plt.ylabel('S(t)')
plt.ylim(0, 1)
plt.show()
```



6. Kaplan-Meier for each PaymentMethod

In [73]:

```
methods = df['PaymentMethod'].value_counts().index.tolist()   # sort from biggest to smallest group
print(methods)
```

```
['Electronic check', 'Mailed check', 'Bank transfer (automatic)', 'Credit card (automatic)']
```

In [74]:

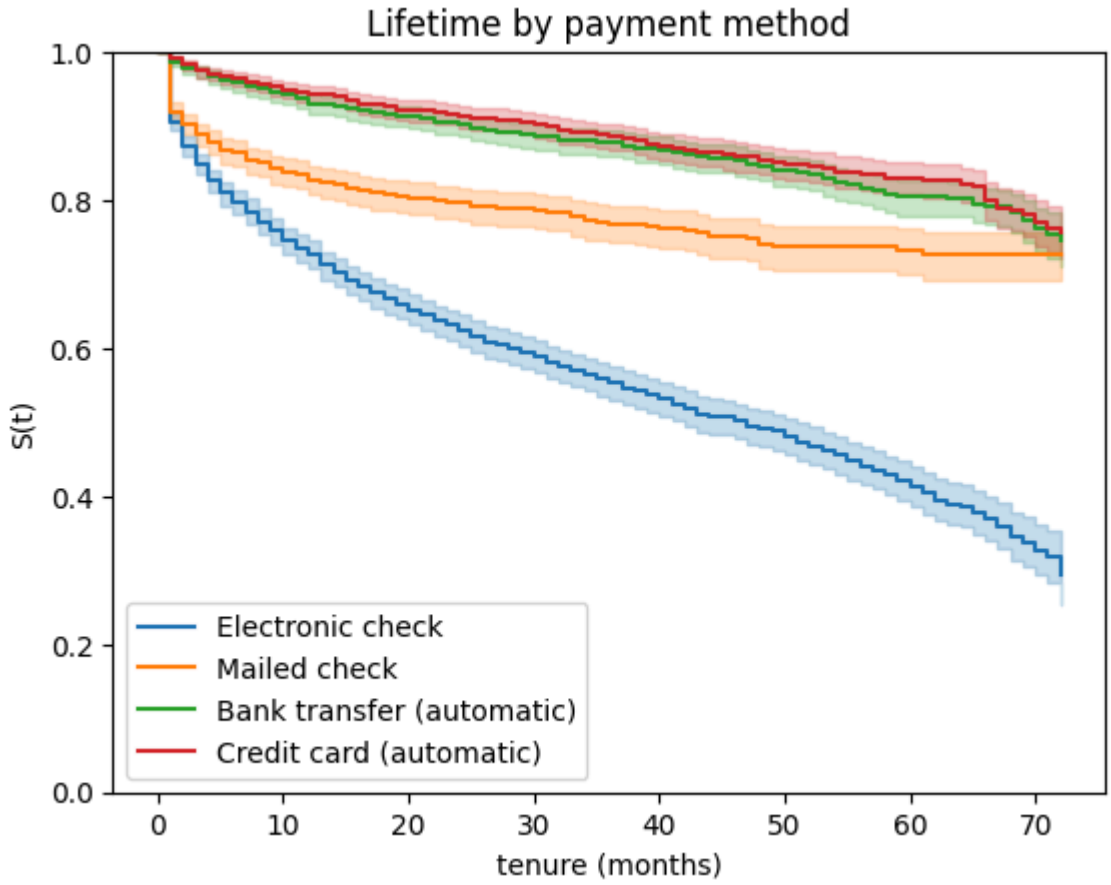
```
ax = plt.subplot(111)
fitters = {}

for m in methods:
    mask = df['PaymentMethod'] == m
    k = KaplanMeierFitter()
    k.fit(T[mask], event_observed=E[mask], label=m)
    k.plot_survival_function(ax=ax, ci_show=True)      # ci_show ไว้ดูว่าเส้นเหลื่อมกันไหม
    fitters[m] = k

    print("%-26s n=%4d  events=%4d  median=%s"
          % (m, mask.sum(), E[mask].sum(), k.median_survival_time_))
```

```
plt.title('Lifetime by payment method')
plt.xlabel('tenure (months)')
plt.ylabel('S(t)')
plt.ylim(0, 1)
plt.show()
```

```
Electronic check           n=2365  events=1071  median=47.0
Mailed check               n=1604  events= 308  median=inf
Bank transfer (automatic)  n=1542  events= 258  median=inf
Credit card (automatic)    n=1521  events= 232  median=inf
```



> 3 ใน 4 กลุ่ม median = `inf` ทำให้ เทียบ "อายุเฉลี่ย" ด้วย median ไม่ได้
> ใช้ 2 อย่างแทน: **S(t) ที่เวลาคงที่** (12/24/48 เดือน) และ **RMST** = พื้นที่ใต้เส้น ถึงเดือนที่ 72
> ตีความได้ว่า "โดยเฉลี่ยอยู่กี่เดือน ภายในกรอบ 72 เดือน"

In [75]:

```
from lifelines.utils import restricted_mean_survival_time as rmst

rows = []
for m, k in fitters.items():
    mask = df['PaymentMethod'] == m
    rows.append({
        'PaymentMethod': m,
        'n':        int(mask.sum()),
        'events':   int(E[mask].sum()),
        'median':   k.median_survival_time_,
        'S(12)':    k.survival_function_at_times(12).iloc[0],
        'S(24)':    k.survival_function_at_times(24).iloc[0],
        'S(48)':    k.survival_function_at_times(48).iloc[0],
        'RMST(72)': rmst(k, t=72),
    })

summary = pd.DataFrame(rows).sort_values('RMST(72)', ascending=False)
print(summary.to_string(index=False))
```

```
          PaymentMethod    n  events  median    S(12)    S(24)    S(48)  RMST(72)
  Credit card (automatic) 1521     232     inf 0.944802 0.912765 0.855388 63.810876
Bank transfer (automatic) 1542     258     inf 0.931131 0.902220 0.847383 62.999594
            Mailed check 1604     308     inf 0.828110 0.796522 0.739521 56.362564
        Electronic check 2365    1071    47.0 0.727032 0.624107 0.492719 41.243145
```

In [76]:

```
s24 = summary['S(24)'].sort_values(ascending=False)
s24_max     = s24.iloc[0]   # แถวที่ 0 หลัง sort = สูงสุด
s24_closest = s24.iloc[1]   # แถวที่ 1 = ใกล้ max ที่สุด
s24_min     = s24.iloc[3]

print(f"S(24) minimum different: {s24_max - s24_closest}")
print(f"S(24) maximum different: {s24_max - s24_min}")
```

```
S(24) minimum different: 0.010544955037039672
S(24) maximum different: 0.28865724878695187
```

7. Check is it just a coincidence? (log-rank test)

H0 = ทุกกลุ่มมี survival curve เดียวกัน

In [77]:

```
from lifelines.statistics import multivariate_logrank_test

res = multivariate_logrank_test(T, df['PaymentMethod'], E)
res.print_summary()

print("p-value =", res.p_value)
```

t_0	-1
null_distribution	chi squared
degrees_of_freedom	3
test_name	multivariate_logrank_test

	test_statistic	p	-log2(p)
0	865.24	<0.005	619.58

```
p-value = 3.0665292229500084e-187
```

In [78]:

```
# pairwise Logrank test
from lifelines.statistics import pairwise_logrank_test

pair = pairwise_logrank_test(T, df['PaymentMethod'], E)

# pandas use e-01 (2 degit) but this p have 3 ditgit (e-113)
print(pair.summary[['test_statistic', 'p']].to_string(
    formatters={'p': lambda x: np.format_float_scientific(
        x, precision=6, unique=False, exp_digits=3
    )}
))
```

```
                                                test_statistic            p
Bank transfer (automatic) Credit card (automatic)       0.868295 3.514278e-001
                          Electronic check            510.035059 6.231417e-113
                          Mailed check                 51.071855 8.904593e-013
Credit card (automatic)   Electronic check            539.740177 2.147615e-119
                          Mailed check                 64.815174 8.226320e-016
Electronic check          Mailed check                152.455455 5.038297e-035
```

8. Summary

- กลุ่มที่อยู่สั้นที่สุดคือ `Electronic check` ส่วนที่อยู่นานที่สุดคือ `Credit card (automatic)`
- S(24) ต่างกันมากที่สุดที่ 0.288 และน้อยที่สุดที่ 0.0105
- log-rank ภาพรวม p = ไม่ปฏิเสธ H0 -> มีนัยะสำคัญทางสถิติว่า survival curve ต่างกัน
- คู่ที่ log-rank บอกว่า **ไม่** ต่างกันคือ `Credit card (automatic)` กับ `Bank transfer (automatic)` (p > 0.05) เพราะ ไม่มีหลักฐานเพียงพอที่จะสรุปว่า survival curves ของทั้งคู่ต่างกัน (ทั้งคู่อาจจะมี survival curves เหมือนกัน)

ตีความเชิงธุรกิจ:

ลูกค้าที่ใช้ `Credit card (automatic)` กับ `Bank transfer (automatic)` มีแนวโน้มของระยะเวลาการเป็นลูกค้า (customer lifetime) สูงกว่ากลุ่มอื่น

โดยที่ `Credit card (automatic)` และ `Bank transfer (automatic)` อาจมี survival curves เหมือนกัน ในขณะที่ `Mailed check` และ `Electronic check` มี survival curves ต่างกัน